

Санкт-Петербургский государственный университет

Ханукаев Виктор Васильевич

Выпускная квалификационная работа

Распределение памяти между дообучением
и калибровкой порогов сетевых детекторов
при возвратном дрейфе

Уровень образования: бакалавриат

Направление *02.03.03 «Математическое обеспечение и администрирование
информационных систем»*

Основная образовательная программа *СВ.5162.2023 «Технологии программирования»*

Научный руководитель:
доцент кафедры системного программирования, к.ф.-м.н., В. И. Гориховский

Рецензент:
пока не назначен

Санкт-Петербург
2026

Saint Petersburg State University

Viktor Khanukaev

Bachelor's Thesis

Memory Allocation Between Fine-Tuning and Threshold Calibration for Network Detectors Under Recurring Concept Drift

Education level: bachelor

Speciality *02.03.03 "Software and Administration of Information Systems"*

Programme *CB.5162.2023 "Programming Technologies"*

Scientific supervisor:
Docent, C.Sc, V. I. Gorikhovskii

Reviewer:
not yet appointed

Saint Petersburg
2026

Оглавление

1. Обзор	4
1.1. Цель обзора и отбор литературы	4
1.2. Изменение нормы и два источника ошибок	4
1.3. Адаптация и сохранение прежних режимов	5
1.4. Отбор данных для хранения и повторного обучения . . .	7
1.5. Совместная адаптация модели и калибровки	7
1.6. Историческая калибровка и разделение данных	8
1.7. Сравнение ближайших работ	9
1.8. Выводы	11
Список литературы	12

1. Обзор

1.1. Цель обзора и отбор литературы

Цель обзора — сопоставить способы адаптации сетевых детекторов, сохранения исторических данных и калибровки порога, чтобы уточнить задачу распределения ограниченной памяти. Рассматриваются работы о непрерывном обучении, возвращающихся распределениях и разделении данных между обучением и калибровкой. Корпус составлен из предварительно отобранных статей.

Сравнение проводится по назначению памяти, способу адаптации, смыслу калибровки и ограничиваемому ресурсу. Лимит разметки, вместимость буфера и число сохраняемых моделей задают разные задачи.

1.2. Изменение нормы и два источника ошибок

Сетевой детектор принимает решение по признакам соединения или потока: длительности, числу пакетов, объёму данных и характеристикам активности. В работе интерес представляет изменение распределения нормального трафика $P_t(X \mid Y = 0)$, где $Y = 0$ обозначает норму. Оно отличается от появления новых атак и изменения их доли. *Возвратный дрейф* означает повторное появление известного распределения после отсутствия, например $A \rightarrow B \rightarrow C \rightarrow A$. Иллюстрацией такого режима является резервное копирование: редкая интенсивная передача допустима, но после перерыва может вызывать тревоги. Изменение нормы исследуется в OWAD, а возвращение распределений — в ARCUS и VLAD [5, 2, 20].

Пусть $s_{\theta_t}(x)$ — численная оценка аномальности наблюдения x . Большему значению соответствует более сильное отклонение от нормы по оценке модели. Здесь θ_t — параметры модели, а τ_t — порог, при превышении которого возникает тревога:

$$\hat{y}_t(x) = \mathbf{1}\{s_{\theta_t}(x) > \tau_t\}. \quad (1)$$

Оценкой может служить ошибка восстановления автоэнкодера или вы-

ход классификатора. Дообучение изменяет оценочную функцию, а калибровка порога выбирает границу решения при фиксированной модели. После обновления модели для сохранённых калибровочных примеров заново вычисляют оценки аномальности: значения, полученные прежней моделью, могут отличаться от новых.

После дообучения ложные тревоги могут учащаться как из-за ухудшения модели, так и из-за несоответствия прежнего порога новым оценкам. Ухудшение на ранее изученных данных после обучения на новых называют *катастрофическим забыванием* [18]. Если при этом оценки нормы и атак сильнее перекрываются, одна перенастройка порога не улучшает способность модели различать их. Во втором случае модель сохраняет способность различать норму и атаки, но численные значения оценок меняются: например, оценки нормального трафика возрастают и начинают превышать прежний порог. Тогда изменение порога может уменьшить число ложных тревог без дообучения модели [14].

1.3. Адаптация и сохранение прежних режимов

Общая задача адаптации к дрейфу уже решается в ADTCD: дистилляция знаний, изменение весов наблюдений и фильтрация выбросов направлены на быстрое обновление без загрязнения обучающих данных [1].

OWAD обнаруживает, объясняет и компенсирует изменения нормального поведения [5]. Историческая контрольная выборка используется для сравнения распределений и адаптации; число её примеров поддерживается постоянным. **Calibrator** преобразует выходы модели для выявления сдвига. Достоинство — учёт изменений нормального поведения и затрат на экспертную разметку. Ограничение состоит в зависимости от правильности меток, которые эксперт присваивает новым наблюдениям: ошибочное обозначение атаки как нормы может привести к тому, что модель начнёт считать такое поведение допустимым.

TAMR сохраняет ограниченное число примеров для повторного обучения; отбор учитывает близость к прототипу задачи, редкость и

давность [3]. Преимущество — сохранение представительных и редких данных. Однако метод использует известные метки задач, а эксперименты организованы как их последовательное введение. Это отличается от возвращения режимов с одной меткой «норма».

SSF рассматривает как сохранение значимых, так и удаление устаревших наблюдений [12]. Метод использует информацию о норме и атаках, экспертную разметку и псевдометки. Его достоинство — явное управление актуальностью обучающей истории. Но неактуальность режима сейчас не исключает его будущего возврата. У Guo и соавторов буфер делится на представителей кластеров и примеры с высокой неопределённостью [11]. Оба поднабора служат обучению, а не независимой оценке распределения нормальных оценок.

Mateen и **ARCUS** сохраняют опыт в нескольких автоэнкодерах [4, 2]. Mateen адаптирует сетевой ансамбль с ограниченной разметкой и проверяет возврат концепций; ARCUS выбирает модель, подходящую текущим данным, либо создаёт новую. Модели, которые формируют близкие внутренние представления данных, объединяются, чтобы сократить их число. Достоинство — повторное использование прежнего представления нормы. В Mateen обучающая база накапливает прежние и новые данные. ARCUS является общим методом обнаружения аномалий, а не только сетевой IDS.

VLAD различает новые и возвращающиеся распределения, организует примеры в иерархическую память и сокращает её при превышении объёма [20]. Сохранённые примеры повторно используются при обновлении вариационного автоэнкодера. Это близкий предшественник по памяти и возвратному дрейфу, но выбор порога тревоги оставлен за пределами метода.

CITADEL сочетает представление маскированного автоэнкодера, детектор новизны и ограниченную иерархическую память со стратегическим отбором [6, 7]. Сильная сторона — управление историей непосредственно в сетевой задаче.

1.4. Отбор данных для хранения и повторного обучения

В MIR буфер содержит случайно отобранную часть прошлых наблюдений. При очередном дообучении используется часть примеров из этого буфера: метод выбирает те, на которых ожидается наибольший рост ошибки после обучения на новых данных [18]. Для этого выполняется пробное обновление и сравниваются значения функции потерь до и после него. Такой отбор помогает сохранить качество модели на примерах, которые могут сильнее пострадать от обновления, но требует дополнительных вычислений. Критерий роста потерь не равнозначен риску тревоги: сильное увеличение ошибки может оставить нормальный пример ниже порога, а небольшое — привести к его пересечению. Таким образом, MIR отбирает примеры по изменению функции потерь, а не непосредственно по появлению ложной тревоги.

CBRS защищает редкие размеченные классы от вытеснения частыми [9]. Его достоинства — простота и небольшие накладные расходы. Алгоритм распределяет память по меткам классов. Если повседневная работа и резервное копирование имеют общую метку «норма», CBRS не различает их как отдельные группы. Поэтому балансировка между нормой и атаками сама по себе не защищает редкий нормальный режим от вытеснения. В этих работах исследуются отбор и повторное использование обучающих примеров, а распределение памяти между обучением и калибровкой не рассматривается.

1.5. Совместная адаптация модели и калибровки

FADES использует конформные сигналы дрейфа и при изменении потока переобучает классификатор и повторно калибрует оценку надёжности по общей истории фиксированного скользящего буфера [13]. **Arrox-CCE** сокращает число обучаемых моделей, а адаптивный размер блока регулирует затраты. Преимущество — целостная потоковая процедура; обновления предполагают надёжные метки. Конформный

порог сигнала дрейфа имеет другое назначение, чем порог сетевой тревоги. Возвратный дрейф оставлен дальнейшим исследованиям.

Statsenko и Bondarenko объединяют вариационный автоэнкодер, энтропийный отбор памяти и динамический порог на основе экспоненциального скользящего среднего (ЕМА) [19]. Порог отслеживается через статистики, а распределение памяти между обучением и отдельными калибровочными примерами не исследуется.

Jeon и Kim выбирают адаптацию возрастающей стоимости: перекалибровку порога, переобучение на смеси старых и новых данных либо обучение только на новом домене [14]. Работа разделяет полезность изменения модели и порога и показывает, что первые поступившие примеры могут плохо представлять последующий поток. Однако ограничивается дополнительная разметка атак; исходная выборка и валидация сохраняются. Авторы признают ретроспективность проверки: валидация включает будущие данные. Кроме того, отрицательный класс отдельных детекторов содержит другие атаки. Поэтому доля ложноположительных решений (FPR) включает ошибки на этих атаках и не характеризует только ложные тревоги на нормальном трафике.

1.6. Историческая калибровка и разделение данных

Replayed Calibration (RC) сохраняет валидационные примеры прошлых этапов и объединяет их с текущими для калибровки после обучения [8]. Достоинство — явное рассмотрение забывания калибровки; обучающая и калибровочная история имеют разные назначения. Однако RC калибрует уверенность классификатора: согласует вероятностные ответы с частотой правильных предсказаний. Это отличается от выбора порога сетевой тревоги, а единый бюджет двух видов памяти в работе не исследуется.

ViC уже разделяет ограниченные примеры старых классов между обучением представления и настройкой линейной коррекции выходов [15]. Сравнение долей показывает компромисс: больше данных для коррекции означает меньше данных для сохранения модели. Коррек-

ция смещения к новым классам отличается от настройки порога тревоги.

Классификация Неймана–Пирсона разделяет примеры класса 0 между обучением оценочной функции и выбором порога; Tong и соавторы также предлагают адаптивный выбор доли [16]. Если класс 0 обозначает норму, задача состоит в уменьшении пропусков атак при ограничении ложных тревог. Достоинство — явные статистические условия. Но анализ относится к независимым стационарным данным; повторный выбор доли не сохраняет автоматически доказанный контроль ошибки. Это ограничивает перенос гарантий на дрейф и адаптивно отбираемую историю.

Das и соавторы оптимизируют разделение конечной выборки между обучением регрессора и калибровкой конформного интервала [17]. Цель — уменьшить его длину при заданном покрытии; эффективная доля зависит от модели и данных. Преимущество — теоретическая формализация компромисса, но покрытие интервала отличается от FPR сетевого детектора.

1.7. Сравнение ближайших работ

Таблица 1 показывает, *что именно сохраняют* методы и *для чего используют* историю. Таблица 2 разделяет разные смыслы калибровки и указывает ограниченный ресурс. Названия методов соответствуют описаниям выше; «не исследуется» означает отсутствие соответствующего сравнения в рассмотренном протоколе.

Таблица 1: Какая история сохраняется для адаптации

Работа	Что хранится	Для чего нужна история
OWAD	Контрольные примеры прежней нормы	Обнаружить изменение нормы и обновить модель
TAMR	Примеры известных задач в ограниченном буфере	Дообучать модель, сохраняя редкие и прежние данные

Продолжение таблицы 1

Работа	Что хранится	Для чего нужна история
SSF	Представительные старые и отобранные новые примеры	Изучать изменения; удалять неактуальные данные
Mateen, ARCUS	Несколько моделей; в Mateen также обучающая история	Повторно использовать модель подходящего режима
VLAD	Примеры распределений в иерархической памяти	Распознавать возвращающийся режим и повторно обучаться на его примерах
CITADEL	Отобранные примеры в ограниченной иерархии	Сохранять значимые распределения при обновлении детектора

Таблица 2: Что калибруется и какой ресурс ограничен

Работа	Что настраивается	Ограничение ресурса
FADES	Конформная оценка надёжности и сигналы дрейфа	Общая скользящая история
Statsenko, Bondarenko	Порог сетевой тревоги по статистикам ЕМА	Ограничено число примеров для повторного обучения
Jeon, Kim	Порог тревоги; затем при необходимости модель	Лимит новой разметки
RC	Уверенность классификатора	Распределение единого бюджета двух видов памяти не исследуется
BiC	Коррекция смещения ответов к новым классам	Примеры старых классов делятся между обучением и коррекцией
Нейман–Пирсон	Порог с ограничением ошибки первого рода	Конечная выборка делится между обучением и порогом
Das и соавторы	Конформный регрессионный интервал	Конечная выборка делится между обучением и калибровкой

1.8. Выводы

Рассмотренные работы уже исследуют *gerplay*, сохранение возвращающихся распределений, историческую калибровку и выбор долей данных. OWAD, TAMR и VLAD показывают, как история помогает адаптировать модель и сохранять сведения о прежних режимах. FADES и работа Statsenko и Bondarenko объединяют адаптацию с калибровочными механизмами. RC использует прошлые данные для калибровки уверенности, а BiC, классификация Неймана–Пирсона и работа Das и соавторов рассматривают разделение данных между двумя процедурами.

Эти направления отвечают на разные вопросы: как сохранить способность модели распознавать прежние данные и как настроить решения после изменения её оценок. Их результаты по отдельности не определяют, как распределять единый ограниченный объём исторических данных между дообучением и калибровкой порога в изменяющемся потоке. Возвращение нормальных режимов делает сохранённую историю вновь полезной и связывает этот вопрос с темой работы.

Список литературы

- [1] ADTCD: An Adaptive Anomaly Detection Approach Toward Concept Drift in IoT / Lijuan Xu, Xiao Ding, Haipeng Peng et al. // [IEEE Internet of Things Journal](#). — 2023. — Vol. 10, no. 18. — P. 15931–15942. — URL: <https://doi.org/10.1109/JIOT.2023.3265964>.
- [2] [Adaptive Model Pooling for Online Deep Anomaly Detection from a Complex Evolving Data Stream](#) / Susik Yoon, Youngjun Lee, Jae-Gil Lee, Byung Suk Lee // Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. — 2022. — P. 2347–2357. — URL: <https://arxiv.org/abs/2206.04792>.
- [3] Adaptive memory replay for network intrusion detection: Tackling data drift and catastrophic forgetting / Nasreen Fathima A H, Ansam Khraisat, Syed Ibrahim S P, Gang Li // [Computer Networks](#). — 2025. — Vol. 272. — P. 111712. — URL: <https://www.sciencedirect.com/science/article/pii/S1389128625006784>.
- [4] Alotaibi Fahad, Maffeis Sergio. [Mateen: Adaptive Ensemble Learning for Network Anomaly Detection](#) // Proceedings of the 27th International Symposium on Research in Attacks, Intrusions and Defenses. — 2024. — P. 215–234. — URL: <https://www.doc.ic.ac.uk/~maffeis/papers/raid24.pdf>.
- [5] [Anomaly Detection in the Open World: Normality Shift Detection, Explanation, and Adaptation](#) / Dongqi Han, Zhiliang Wang, Wenqi Chen et al. // Proceedings of the Network and Distributed System Security Symposium. — 2023. — URL: <https://www.ndss-symposium.org/wp-content/uploads/2023-830-paper.pdf>.
- [6] Li Elvin, Gungor Onat, Shang Zhengli, Rosing Tajana. CITADEL: Continual Anomaly Detection for Enhanced Learning in IoT Intrusion Detection. — arXiv:2508.19450v1. — 2025. — DOI: [10.48550/arXiv.2508.19450](https://doi.org/10.48550/arXiv.2508.19450). URL: <https://arxiv.org/abs/2508.19450v1>.

- [7] CITADEL: Continual Anomaly Detection for Enhanced Learning in intrusion detection systems / Elvin Li, Onat Gungor, Zhengli Shang et al. // [Computer Networks](#). — 2026. — Vol. 285. — P. 112398. — URL: <https://www.sciencedirect.com/science/article/pii/S138912862600410X>.
- [8] [Calibration of Continual Learning Models](#) / Lanpei Li, Elia Piccoli, Andrea Cossu et al. // CLVISION Workshop, CVPR 2024. — 2024. — arXiv:2404.07817v2. URL: <https://arxiv.org/abs/2404.07817v2>.
- [9] Chrysakis Aristotelis, Moens Marie-Francine. Online Continual Learning from Imbalanced Data // Proceedings of the 37th International Conference on Machine Learning. — Vol. 119. — 2020. — P. 1952–1961. — URL: <https://proceedings.mlr.press/v119/chrysakis20a.html>.
- [10] Li Lanpei, Piccoli Elia, Cossu Andrea et al. Continual-Calibration: author implementation. — GitHub repository. — 2024. — URL: <https://github.com/lilanpei/Continual-Calibration/tree/026926ae98c48aef0d0ea26a985fa2a4a3844453>.
- [11] Continual Learning for Intrusion Detection Under Evolving Network Threats / Chaoqun Guo, Xihan Li, Jubao Cheng et al. // [Future Internet](#). — 2025. — Vol. 17, no. 10. — P. 456. — URL: <https://www.mdpi.com/1999-5903/17/10/456>.
- [12] [Continual Learning with Strategic Selection and Forgetting for Network Intrusion Detection](#) / Xinchun Zhang, Running Zhao, Zhihan Jiang et al. // IEEE INFOCOM 2025 — IEEE Conference on Computer Communications. — 2025. — P. 1–10. — URL: <https://arxiv.org/abs/2412.16264v2>.
- [13] FADES: Adaptive Drift Estimation via Conformal Signals for Streaming Intrusion Detection / Seth Barrett, Gokila Dorai, Lin Li, Swarnamugi Rajaganapathy // [Electronics](#). — 2026. — Vol. 15, no. 10. — P. 2114. — URL: <https://www.mdpi.com/2079-9292/15/10/2114>.

- [14] Jeon Sanghoon, Kim Aram. A Label-Efficient Adaptive Retraining Framework for Network Intrusion Detection Under Streaming Arrival Bias // *Electronics*. — 2026. — Vol. 15, no. 17. — P. 3812. — URL: <https://www.mdpi.com/2079-9292/15/17/3812>.
- [15] Wu Yue, Chen Yinpeng, Wang Lijuan et al. Large Scale Incremental Learning. — arXiv:1905.13260. — 2019. — DOI: [10.48550/arXiv.1905.13260](https://arxiv.org/abs/1905.13260). URL: <https://arxiv.org/abs/1905.13260>.
- [16] Neyman-Pearson classification: parametrics and sample size requirement / Xin Tong, Lucy Xia, Jiacheng Wang, Yang Feng // *Journal of Machine Learning Research*. — 2020. — Vol. 21, no. 12. — P. 1–48. — URL: <https://www.jmlr.org/papers/v21/18-577.html>.
- [17] Das Sayan, Yaghooti Bahram, Kuffner Todd A., Lahiri Soumen- dra N. On Optimal Data Splitting for Split Conformal Prediction. — arXiv:2606.31600v1. — 2026. — DOI: [10.48550/arXiv.2606.31600](https://arxiv.org/abs/2606.31600). URL: <https://arxiv.org/abs/2606.31600v1>.
- [18] Aljundi Rahaf, Caccia Lucas, Belilovsky Eugene et al. Online Contin- ual Learning with Maximally Interfered Retrieval. — arXiv. — 2019. — DOI: [10.48550/arXiv.1908.04742](https://arxiv.org/abs/1908.04742). URL: <https://arxiv.org/abs/1908.04742v3>.
- [19] Statsenko Volodymyr, Bondarenko Anton. Adaptive Continual Learn- ing for Intrusion Detection Systems: Entropy-Based Memory Manage- ment and Dynamic Threshold Calibration // *Technologies and En- gineering*. — 2025. — Vol. 26, no. 5. — P. 91–99. — URL: <https://jrn1.knutd.edu.ua/index.php/techeng/article/view/1953>.
- [20] VLAD: Task-agnostic VAE-based lifelong anomaly detection / Kamil Faber, Roberto Corizzo, Bartłomiej Śnieżyński, Nathalie Jap- kowicz // *Neural Networks*. — 2023. — Vol. 165. — P. 248–273. — URL: <https://www.sciencedirect.com/science/article/pii/S0893608023002733>.

- [21] gserpep. Replay+TS+RC results: Issue 7 in Continual-Calibration. — GitHub issue. — 2025. — URL: <https://github.com/lilanpei/Continual-Calibration/issues/7>.